

Проверка логической согласованности ключевых переменных

Для каждого столбца выполняются два уровня контроля: (1) проверка допустимости значения - тип данных, пропуски, отрицательные или нулевые значения; (2) проверка логической согласованности - сравнение показателя с другими связанными переменными, из которых он должен рассчитываться или с которыми должен совпадать.

1. DAYSSINCELASTORDER

Столбец показывает, сколько дней прошло с последнего заказа клиента.

Проверка допустимости

Проверить, является ли столбец числовым, отсутствуют ли пропуски, отрицательные значения и явно нереалистичные экстремальные значения. Отрицательное значение невозможно, поскольку последняя покупка не должна находиться в будущем относительно даты анализа.

Проверка логической согласованности

$\text{DAYSSINCELASTORDER} = \text{Reference Date} - \text{LATEST_ORDER_DATE}$

Если дата анализа известна, нужно заново вычислить количество дней между ней и LATEST_ORDER_DATE и сравнить с готовым столбцом. Допуск в один день возможен из-за времени суток или округления.

Если дата анализа неизвестна, её можно восстановить для каждой строки:

$\text{Inferred Reference Date} = \text{LATEST_ORDER_DATE} + \text{DAYSSINCELASTORDER}$

В логически согласованном датасете восстановленная дата должна быть одинаковой или почти одинаковой у большинства клиентов.

Пример проверки в Python:

```
reference_date = pd.Timestamp('2025-12-31')
df['CALCULATED_DAYS'] = (reference_date - df['LATEST_ORDER_DATE']).dt.days
df['DAYS_DIFF'] = df['DAYSSINCELASTORDER'] - df['CALCULATED_DAYS']
df[df['DAYS_DIFF'].abs() > 1]
```

2. AVGDAYS BETWEEN ORDERS

Столбец показывает среднее количество дней между последовательными заказами клиента.

Проверка допустимости

Проверить числовой тип, пропуски, отрицательные значения и нули для клиентов с несколькими заказами. Для клиента с одним заказом средний интервал не определён, поэтому допустимы NaN или специальное обозначение, но не следует интерпретировать ноль как реальный интервал.

Проверка логической согласованности

$\text{Expected AVGDAYS BETWEEN ORDERS} = (\text{LATEST_ORDER_DATE} - \text{FIRST_ORDER_DATE}) / (\text{TOTAL_ORDERS} - 1)$

В знаменателе используется TOTAL_ORDERS - 1, потому что между двумя заказами существует один интервал, между тремя - два, между десятью - девять. Проверка проводится только для клиентов с TOTAL_ORDERS > 1.

Пример проверки в Python:

```
mask = df['TOTAL_ORDERS'] > 1
df.loc[mask, 'CALCULATED_AVG_DAYS'] = ((df.loc[mask, 'LATEST_ORDER_DATE'] - df.loc[mask, 'FIRST_ORDER_DATE']).dt.days / (df.loc[mask, 'TOTAL_ORDERS'] - 1))
df.loc[mask, 'AVG_DAYS_DIFF'] = df.loc[mask, 'AVGDAYS BETWEEN ORDERS'] - df.loc[mask, 'CALCULATED_AVG_DAYS']
df[mask & (df['AVG_DAYS_DIFF'].abs() > 1)]
```

3. REVENUE

Столбец отражает общую выручку, полученную от клиента.

Проверка допустимости

Проверить числовой формат, пропуски, отрицательные значения, нулевую выручку при положительном числе заказов и экстремальные значения. Отрицательная выручка может означать возвраты или корректировки, поэтому её нельзя удалять автоматически без понимания бизнес-смысла.

Проверка логической согласованности

Общая выручка должна приблизительно совпадать с суммой выручки в каждом независимом разрезе данных:

$REVENUE \approx MONDAY_REVENUE + \dots + SUNDAY_REVENUE$

$REVENUE \approx WEEK1_REVENUE + WEEK2_REVENUE + WEEK3_REVENUE + WEEK4_REVENUE$

$REVENUE \approx TIME_00_06_REVENUE + TIME_06_12_REVENUE + TIME_12_18_REVENUE + TIME_18_24_REVENUE$

Каждый разрез проверяется отдельно. Суммы по дням недели, неделям месяца и времени суток не складываются друг с другом, поскольку это три разных представления одной и той же общей выручки. Для денежных значений допустим небольшой порог, например 0,01-0,05 евро.

Пример проверки по дням недели:

```
weekday_cols = ['MONDAY_REVENUE', 'TUESDAY_REVENUE', 'WEDNESDAY_REVENUE', 'THURSDAY_REVENUE', 'FRIDAY_REVENUE', 'SATURDAY_REVENUE', 'SUNDAY_REVENUE']
df['WEEKDAY_REVENUE_SUM'] = df[weekday_cols].sum(axis=1)
df['REVENUE_DIFF'] = df['REVENUE'] - df['WEEKDAY_REVENUE_SUM']
df[df['REVENUE_DIFF'].abs() > 0.01]
```

4. AVERAGE_ORDER_VALUE

Столбец показывает среднюю выручку на один заказ.

Проверка допустимости

Проверить числовой тип, пропуски, отрицательные значения и невозможные значения при нулевом количестве заказов.

Проверка логической согласованности

$AVERAGE_ORDER_VALUE \approx REVENUE / TOTAL_ORDERS$

Расчёт выполняется только при $TOTAL_ORDERS > 0$. Небольшие расхождения допустимы из-за округления. Большие расхождения могут указывать на разные периоды расчёта, различный учёт возвратов или доставки, ошибку агрегации либо ошибочное исходное значение.

Пример проверки в Python:

```
mask = df['TOTAL_ORDERS'] > 0
df.loc[mask, 'CALCULATED_AOV'] = df.loc[mask, 'REVENUE'] / df.loc[mask, 'TOTAL_ORDERS']
df.loc[mask, 'AOV_DIFF'] = df.loc[mask, 'AVERAGE_ORDER_VALUE'] - df.loc[mask, 'CALCULATED_AOV']
df[mask & (df['AOV_DIFF'].abs() > 0.01)]
```

Рекомендуемая последовательность

Шаг	Действие
1	Проверить базовые поля: CustomerID, TOTAL_ORDERS, FIRST_ORDER_DATE и LATEST_ORDER_DATE.
2	Проверить DAYSSINCELASTORDER относительно LATEST_ORDER_DATE и общей даты анализа.

Шаг	Действие
3	Проверить AVGDAYSBETWEENORDERS относительно первой даты, последней даты и числа заказов.
4	Проверить REVENUE через суммы выручки по дням, неделям и времени суток.
5	Проверить AVERAGE_ORDER_VALUE через $REVENUE / TOTAL_ORDERS$.
6	Только после этого рассчитывать производные показатели, например Inactivity Ratio.

Итог: сначала проверяются исходные переменные, затем вычисляются новые показатели. Нельзя рассчитывать производную метрику из столбцов, корректность которых ещё не подтверждена.